LAB 2 — NHẬN DIỆN CẢM XÚC KHUÔN MẶT

Deep Learning • FER-2013 • CNN và ResNet18 Transfer Learning

1. Mục tiêu và phạm vi

Xây dựng pipeline nhận diện cảm xúc khuôn mặt gồm đọc ảnh/video, phát hiện khuôn mặt, tiền xử lý, phân loại cảm xúc và hiển thị bounding box, nhãn dự đoán, confidence và FPS. Hai mô hình được đánh giá độc lập trên tập test FER-2013: M1 là CNN tự thiết kế; M2 là ResNet18 sử dụng Transfer Learning.

2. Dữ liệu và tiền xử lý

Bộ dữ liệu sử dụng là FER-2013 được cung cấp trong project, gồm ảnh khuôn mặt grayscale 48×48 và 7 nhãn: angry, disgust, fear, happy, neutral, sad, surprise. Tổng cộng có 35.887 ảnh: 28.709 ảnh train và 7.178 ảnh test. Tập train được chia phân tầng (stratified) thành 90% train và 10% validation; tập test được giữ riêng cho đánh giá cuối cùng.

Lớp	Train	Test	Nhận xét
Angry	3.995	958	
Disgust	436	111	Ít ảnh
Fear	4.097	1.024	
Happy	7.215	1.774	Nhiều nhất
Neutral	4.965	1.233	
Sad	4.830	1.247	
Surprise	3.171	831	
Tổng	**28.709**	**7.178**	

Mất cân bằng lớp: Disgust có 436 ảnh train trong khi Happy có 7.215 ảnh. Khi huấn luyện, sử dụng class-weighted cross entropy để tăng ảnh hưởng của các lớp ít mẫu. Train augmentation gồm lật ngang và xoay nhẹ; không bổ sung bộ dữ liệu ngoài FER-2013.

3. Kiến trúc mô hình và thiết lập huấn luyện

M1 — CNN tự thiết kế

CNN gồm 4 block kiểu VGG, mỗi block có 2 lớp Conv2D → BatchNorm → ReLU rồi MaxPooling; số kênh tăng dần 32, 64, 128, 256. Sau các khối tích chập, đặc trưng được Flatten, đưa qua lớp Linear 256, ReLU, Dropout 0,45 và lớp đầu ra 7 logits. Đầu vào là ảnh grayscale 48×48; chuẩn hóa bằng mean/std 0,5.

M2 — ResNet18 Transfer Learning

M2 sử dụng ResNet18 với backbone khởi tạo từ trọng số ImageNet và thay lớp fully connected bằng dropout 0,3 cùng lớp Linear 7 đầu ra. Ảnh grayscale được chuyển thành 3 kênh, resize về 224×224 và chuẩn hóa theo mean/std ImageNet.

Thiết lập chung

Optimizer: AdamW; weight decay 1e-4. Learning rate mặc định của mã huấn luyện: 1e-3 cho CNN và 1e-4 cho Transfer Learning. Dùng class weights trong CrossEntropyLoss; chọn checkpoint theo Macro F1 trên validation. Kết quả được lấy từ các file JSON/ảnh xuất sau quá trình huấn luyện trên Google Colab.

Chỉ tiêu	M1 — CNN	M2 — ResNet18
Epoch có trong history	60	10
Train images	25.838	25.838
Validation images	2.871	2.871
Test images	7.178	7.178
Số tham số	1.764.519	11.180.103

4. So sánh kết quả trên tập test

Metric	Ngưỡng đề ra	M1 — CNN	M2 — ResNet18
Accuracy	≥60% / ≥65%	63,69%	66,30%
Macro F1-score	Báo cáo	62,30%	64,35%
Tham số	So sánh	1.764.519	11.180.103
Đánh giá Accuracy	Đạt yêu cầu	Đạt	Đạt

M2 cao hơn M1 2,61 điểm phần trăm về Accuracy và 2,05 điểm phần trăm về Macro F1, nhưng có khoảng 6,3 lần số tham số. Macro F1 tính trung bình F1 của các lớp, giúp đánh giá cân bằng hơn khi số ảnh giữa các lớp khác nhau.

5. Đồ thị huấn luyện (M5)

Các đồ thị được dùng để theo dõi quá trình học và khả năng tổng quát hóa. Train loss giảm trong khi validation loss tăng hoặc validation accuracy dao động có thể là dấu hiệu overfitting.

Mô hình	Số epoch	Quan sát
M1 — CNN	60	Train loss giảm; validation loss dao động. Nên chọn checkpoint theo metric valida
M2 — ResNet18 Transfer Learning	10	Train loss tiếp tục giảm, trong khi validation loss có xu hướng tăng sau các epoch

Diễn giải

CNN được huấn luyện qua 60 epoch; ResNet18 qua 10 epoch. Với ResNet18, train loss tiếp tục giảm nhưng validation loss có xu hướng tăng sau các epoch đầu. Vì vậy, nên chọn checkpoint dựa trên metric validation thay vì chỉ dựa vào train accuracy.

6. Confusion Matrix và lỗi phân loại (M4)

Confusion Matrix thể hiện số lượng dự đoán đúng/sai theo từng lớp; hàng là nhãn thật, cột là nhãn dự đoán. Các lỗi có thể tập trung ở những biểu cảm có đặc điểm thị giác tương tự nhau, đặc biệt fear, sad, angry và neutral.

Khi phân tích lỗi, nên xem ảnh gốc, nhãn thật, nhãn dự đoán và confidence. Confidence thấp có thể cho thấy biểu cảm mơ hồ, khuôn mặt nhỏ hoặc điều kiện ảnh không thuận lợi. Không nên kết luận chỉ từ một vài ví dụ; cần đối chiếu với confusion matrix và metric tổng thể.

7. Phân tích lỗi và ứng dụng realtime

Phân tích một số dự đoán sai

Các ví dụ lỗi được lưu trong file misclassified_examples.csv và ảnh minh họa misclassified_grid.jpg (nếu có trong thư mục kết quả). Mỗi ví dụ nên được kiểm tra theo các yếu tố: nhãn thật, nhãn dự đoán, confidence, chất lượng ảnh và đặc điểm biểu cảm.

M1 — CNN

Các ví dụ được ghi nhận gồm trường hợp nhãn thật angry nhưng mô hình dự đoán sad hoặc fear; một số trường hợp có confidence ở mức trung bình. Cần xem lại ảnh gốc để xác nhận nguyên nhân cụ thể, tránh suy luận chỉ từ nhãn.

M2 — ResNet18

Các ví dụ được ghi nhận gồm trường hợp nhãn thật angry nhưng dự đoán sad, neutral hoặc disgust. Confidence có thể cao ngay cả khi dự đoán sai; vì vậy confidence không đồng nghĩa với độ chính xác.

Ứng dụng realtime và cách chạy

Ứng dụng dùng OpenCV Haar Cascade để phát hiện nhiều khuôn mặt, sau đó tiền xử lý từng vùng mặt và dự đoán cảm xúc, confidence và FPS. Có thể đọc video từ camera máy tính hoặc camera ảo iVCam.

Lệnh chạy từ camera iVCam (camera số 0):

```
python src/app.py --source 0 --model cnn
```

```
python src/app.py --source 0 --model transfer
```

Nếu dùng IP Webcam, thay 0 bằng URL luồng video chính xác của ứng dụng. Với iVCam, cần mở iVCam Client trên laptop và đảm bảo điện thoại đã kết nối trước khi chạy Python.

Lưu ý khi đo FPS: số liệu trong JSON có thể là throughput của suy luận theo batch trên thiết bị huấn luyện, không phải FPS end-to-end của camera trên CPU. FPS realtime phụ thuộc vào tốc độ đọc camera, phát hiện khuôn mặt, tiền xử lý và suy luận.

8. Kết luận

Trên FER-2013, M1 đạt Accuracy 63,69% và M2 đạt 66,30%; M2 có kết quả tốt hơn trong thí nghiệm này nhưng số tham số lớn hơn đáng kể. Khi chạy realtime trên CPU, cần kiểm tra FPS thực tế, độ ổn định của camera và chất lượng dự đoán. Hướng cải thiện gồm tăng cường dữ liệu, xem xét mất cân bằng lớp, tối ưu tốc độ suy luận và đánh giá thêm trên ảnh thực tế.

BỔ SUNG KẾT QUẢ CHẠY THỬ THỰC TẾ

9. Kiểm thử ứng dụng nhận diện cảm xúc theo thời gian thực

Sau khi tích hợp camera iVCam và chạy thử ứng dụng trên máy tính, cả hai mô hình CNN và Transfer Learning đều đạt tốc độ xử lý khoảng 30 FPS trong điều kiện thử nghiệm. Kết quả này đáp ứng yêu cầu tốc độ theo thời gian thực của bài Lab.

Tiêu chí	CNN	Transfer Learning
Nguồn video	Camera iVCam	Camera iVCam
FPS quan sát được	Khoảng 30 FPS	Khoảng 30 FPS
Đánh giá realtime	Đạt yêu cầu	Đạt yêu cầu; kết quả quan sát tốt hơn

Nhận xét kết quả

Trong quá trình chạy thử, mô hình Transfer Learning cho kết quả realtime tốt hơn theo quan sát thực tế, thể hiện ở chất lượng dự đoán/độ ổn định của kết quả hiển thị. Cả hai mô hình đều duy trì tốc độ khoảng 30 FPS. Như vậy, trong môi trường kiểm thử này, Transfer Learning là lựa chọn phù hợp hơn khi ưu tiên chất lượng nhận diện theo thời gian thực.

Lưu ý: Mức khoảng 30 FPS là kết quả quan sát trong lần chạy thử trên hệ thống hiện tại; tốc độ thực tế có thể thay đổi theo cấu hình máy tính, nguồn video, kích thước khung hình và điều kiện ánh sáng.